

개와 고양이로 이해하는 딥러닝 · 신경망 · 임베딩

5주차 보조자료

2026학년도 1학기 | 인공지능과 인문학

송영숙

01 딥러닝이 무엇인지 이해한다

사람이 규칙을 쓰는 방식과, 컴퓨터가 직접 배우는 방식의 차이를 안다

02 신경망의 기본 구조를 설명할 수 있다

입력층, 숨겨진 층, 출력층의 역할과 '깊이'의 의미를 안다

03 임베딩의 원리와 CLIP의 역할을 이해한다

사진과 문장이 '숫자 리스트'로 바뀌고, 같은 지도 위에 놓이는 과정을 안다


1. 컴퓨터는 숫자밖에 모른다

사진도 글도 전부 숫자 — AI의 출발점

사진은 숫자 더미

사진 한 장 = 3만 칸짜리 엑셀 스프레드시트

- 가로 100 × 세로 100 = 1만 개의 칸(픽셀), 각 칸에 밝기 숫자 0~255
- 컬러 사진 → 빨강·초록·파랑 3장 겹침 → 숫자 3만 개
- 컴퓨터는 이 숫자만 읽을 수 있음 — '귀가 뵈족한가' 같은 판단은 직접 해야 함




사진은 숫자 더미


텍스트도 마찬가지로

- '고양이' → ㄱ=몇 번, ㅊ=몇 번, ㅅ=몇 번 ... 전부 숫자로 변환
- 결국 AI에게 무언가를 알려주려면 '모든 것을 숫자로 번역'하는 과정이 필요

이 '번역' 개념이 뒤에서 다룰 임베딩(embedding)의 출발점



확률과 의미적 유사성 사이의 거리(벡터)로 표현됨



- 카프치노랑 에스프레소는 코사인 유사도에서 바로 옆에 있으니까 아무거나 드세요라고 할 수 없음
- 이 모든 움직임의 시작이었던 임베딩 능력의 고도화를 다시 생각해 볼 필요가 있음
- 유사한 문장과 유사하지 않은 문장을 구별하는 데이터 세트 (NLI, STS, QA)를 통한 모델 고도화 필요
- 전문 분야에서 차별화된 전략을 구사하기 위해서는 위의 두 가지 전략이 전제되어야 함

"AI가 사진을 눈으로 본다?"

AI에게 눈은 없음 — 숫자 더미를 계산해 패턴을 찾는 것뿐
'사진을 이해한다'는 표현도 엄밀히는 틀림
AI는 통계적 규칙성을 학습할 뿐, 사람처럼 '의미'를 파악하지 못함

앞으로 배울 것 미리 보기 — '비슷함'을 어떻게 잴까?

AI가 사진을 숫자 리스트로 바꾸고 나면, 남은 질문은 하나:


"이 두 리스트가 얼마나 비슷한가?"

비유: 나침반의 방향

- 숫자 리스트를 화살표로 바꿔서 생각해 보자
- 고양이 사진 A의 화살표와 고양이 사진 B의 화살표 → 거의 같은 방향을 가리킴
- 고양이 사진 A의 화살표와 강아지 사진 C의 화살표 → 전혀 다른 방향을 가리킴
- 같은 방향 = 비슷한 사진, 다른 방향 = 다른 사진

이 '방향의 유사함'을 숫자로 나타낸 것이 코사인 유사도(cosine similarity)

코사인 유사도 — 방향이 비슷하면 '가까운' 것



왼쪽: 고양이끼리는 각도 10° (유사도 0.98) | 가운데: 고양이↔강아지는 각도 70° (유사도 0.34) | 오른쪽: 나침반 비유

코사인 유사도 — 이것만 기억하면 됨

유사도 = 1에 가까움

- 두 화살표가 거의 같은 방향
- 고양이 A와 고양이 B처럼 '비슷한 사진'
- 나침반 두 개가 모두 북쪽을 가리키는 상태

유사도 = 0에 가까움

- 두 화살표가 전혀 다른 방향
- 고양이 A와 강아지 C처럼 '다른 사진'
- 나침반 하나는 북쪽, 하나는 동쪽을 가리키는 상태

AI는 이 값을 보고 '이 사진은 고양이에 가깝다'고 판단

수식을 몰라도 괜찮음 — '방향이 같으면 비슷, 다르면 다르다'가 전부

2. 개와 고양이를 구분하는 문제

AI의 가장 기본적인 과제

규칙을 사람이 쓰는가, 컴퓨터가 찾는가

옛날 방식 (전통 프로그래밍)

- 사람이 직접 규칙을 작성
- '귀가 뽀족하면 고양이' 같은 조건문
- 예외가 끝없이 발생 (치와와, 스코티시 폴드...)

딥러닝

- 컴퓨터가 수천 장의 사진을 보며 직접 규칙 발견
- 정답(라벨)만 알려주면, 어떤 특징이 중요한지는 자동으로 학습
- 예외에도 유연하게 대응 가능

비유: 공식집 암기 vs 문제를 수천 개 풀어보며 감 잡기

흔한 오해: 'AI에게 귀가 뽀족하면 고양이라고 가르쳐야 한다'
→ 딥러닝에서는 특징을 사람이 알려주지 않음. 정답만 알려주면 됨

3. 신경망

뇌를 아주 단순하게 흉내 낸 구조

신경망 구조 — 개와 고양이 분류



세 가지 층의 역할

입력층 = 우편 수발실

사진의 픽셀 숫자가 우편물처럼 들어오는 곳

숨겨진 층 = 분석 팀

픽셀을 조합해 '귀 모양', '줄무늬 패턴' 같은 특징을 자동으로 추출

출력층 = 최종 보고서

'개 20%, 고양이 80%' 같은 최종 답

깊이의 비유: 자모(ㄱ, ㅏ) → 글자(가, 나) → 단어(고양이)

한 층만으로는 자모밖에 모르지만, 층을 쌓으면 단어까지 이해 가능

4. 학습이란


틀리고, 고치고, 다시 시도하기

학습의 흐름 — 네 단계 반복

- ① 사진을 넣는다 고양이 사진 한 장을 신경망에 통과
- ② 답을 확인한다 '개 70%, 고양이 30%' → 정답과 비교 → 손실(loss) 계산
- ③ 가중치를 조절한다 손실을 줄이는 방향으로 '볼륨 슬라이더'를 아주 조금씩 조정
- ④ 다음 사진으로 넘어간다 다른 사진으로 ①~③ 반복

이 과정을 수만 번 반복 → 가중치가 좋은 값으로 수렴 → '학습 완료'

학습 과정 — 손실 감소, 정확도 상승



빨간 선(손실)이 내려가고, 초록 선(정확도)이 올라가는 모습

소금·설탕·간장의 양 = 가중치

- 처음에는 양이 엉뚱해서 맛이 이상함
- 한 입 먹어 보고(= 정답과 비교), '짜다'(= 손실이 크다)는 피드백을 받으면
- 소금을 약간 줄임(= 가중치 조절)
- 수백 번 반복 → 맛있는 레시피(= 좋은 가중치) 완성

흔한 오해: 'AI는 한 번에 정답을 배운다'

한 장의 사진만 보여주면 아무것도 배우지 못함
수천, 수만 장을 보여주고 매번 가중치를 수정해야 비로소 판단 가능

5. 임베딩

이미지와 텍스트를 '지도 위의 좌표'로 바꾸기

사진이나 문장을 일정 길이의 숫자 리스트(벡터)로 바꾸는 것


이미지 임베딩 예시

```
고양이 사진 A → [0.12, -0.34, 0.78, ..., 0.05] (512개 숫자)  
고양이 사진 B → [0.11, -0.31, 0.75, ..., 0.06] ← A와 비슷!  
강아지 사진 C → [0.95, 0.44, -0.21, ..., 0.88] ← A와 다름!
```

비유: 800쪽 소설의 한 문단 요약 → 요약끼리 비교하면 비슷한 이야기인지 금방 파악

비슷한 사진은 숫자 리스트도 비슷 / 다른 사진은 숫자 리스트도 다름

임베딩 공간 — 비슷한 사진은 가까이 모인다



고양이(주황) = 서울 근처, 강아지(청록) = 부산 근처, 별 = 처음 보는 사진

텍스트에도 같은 원리

"고양이가 소파에 앉아 있다" → [0.22, -0.15, 0.63, ..., 0.11]
"고양이가 의자 위에 있다" → [0.20, -0.13, 0.60, ..., 0.12] ← 비슷!
"자동차가 도로를 달린다" → [0.88, 0.55, -0.40, ..., 0.77] ← 다름!

임베딩이 쓰이는 곳

- 네이버 '고양이 사진' 검색 → 비슷한 이미지 줄줄이 표시
- 유튜브 '이 영상을 좋아하셨다면...' → 임베딩으로 비슷한 영상 추천
- 쿠팡 '이 상품과 비슷한 상품' → 상품 임베딩 기반 추천

핵심: '비슷한가?'라는 질문을 숫자 계산 한 번으로 답할 수 있음

6-7. CLIP

<https://arxiv.org/abs/2103.00020>

이미지와 텍스트를 같은 지도 위에 올리다

이미지 임베딩과 텍스트 임베딩은 원래 따로 논다

서로 다른 지도, 같은 좌표

서울 지도의 (37.5, 127.0)과 뉴욕 지도의 (37.5, 127.0)

→ 같은 좌표이지만 전혀 다른 장소

이미지 신경망이 만든 [0.5, 0.3, ...]과 텍스트 신경망이 만든 [0.5, 0.3, ...]

→ 숫자가 같아도 다른 의미

같은 지도 위에 놓이지 않으면 비교 불가 → CLIP이 이 문제를 해결

CLIP — 이미지와 텍스트를 같은 공간에서 비교



이미지 인코더 + 텍스트 인코더 → 같은 좌표계의 벡터 → 유사도 비교

CLIP으로 개와 고양이 분류하기

- ① 처음 보는 사진 → 이미지 인코더 → 숫자 리스트
- ② "고양이 사진" → 텍스트 인코더 → 숫자 리스트
- ③ "강아지 사진" → 텍스트 인코더 → 숫자 리스트
- ④ 사진의 리스트가 어느 쪽에 더 가까운가? → 판정

CLIP의 장점: 라벨을 문장으로 넣을 수 있음

→ 학습할 때 없던 '햄스터 사진'이라는 문장을 넣으면 햄스터도 분류 가능

정리: 세 가지 핵심 개념

개념	한 줄 요약	비유
딥러닝	예시를 보고 컴퓨터가 직접 규칙을 찾는 방법	문제를 수천 개 풀며 감 잡기
신경망 (아키텍처)	뉴런을 여러 층으로 쌓은 구조 깊을수록 복잡한 특징 포착	자모 → 글자 → 단어
임베딩	사진·문장을 숫자 리스트(좌표)로 변환 비슷한 것끼리 좌표가 가까움	소설의 한 문단 요약

AI 이미지 생성의 원리

- ① 텍스트 인코더가 프롬프트 → 숫자 리스트를 만들 (CLIP)
- ② 이 숫자 리스트를 목표로, 순수 노이즈 이미지에서 출발
- ③ 확산 모델이 노이즈를 조금씩 제거하며 이미지를 다듬어감
- ④ 50번 반복 → 프롬프트에 맞는 이미지 완성

지금까지 읽은 개념(임베딩, 신경망, 학습)이 이 과정의 뿌리에 깔려 있음